

▼ Bibliotecas

```

1 import pandas as pd
2
3 import plotly.graph_objects as go
4 import plotly.express as px
5 from plotly.subplots import make_subplots
6 import seaborn as sns
7
8 from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
9 from sklearn.model_selection import train_test_split
10 from sklearn.svm import LinearSVR
11 from sklearn.preprocessing import PolynomialFeatures
12 from sklearn.linear_model import LinearRegression
13 from sklearn.ensemble import RandomForestRegressor
14 from sklearn.dummy import DummyRegressor

```

▼ Dados

```

1 source = 'https://raw.githubusercontent.com/alura-cursos/imersao-dados-2-2020/ma
2
3 data = pd.read_csv(source)
4
5 data.head()

```

	NU_INSCRICAO	NU_ANO	CO_MUNICIPIO_RESIDENCIA	NO_MUNICIPIO_RESIDENCIA	CO_1
0	190001004661	2019	1506138	Redenção	
1	190001004674	2019	1504208	Marabá	
2	190001004722	2019	1501402	Belém	
3	190001004735	2019	1507300	São Félix do Xingu	
4	190001004776	2019	1500800	Ananindeua	

5 rows x 136 columns

▼ Dia 1 - Desafios

▼ Desafio 1 - Proporção de inscritos por idade

```
1 # Desafio 1
```

```

2
3 percentagem_idade = data["NU_IDADE"].value_counts().sort_index() / len(data["NU_
4
5 percentagem_idade = pd.DataFrame(percentagem_idade).reset_index(inplace=False)
6
7 percentagem_idade.columns = ['Idade', 'Porcentagem (%)']
8
9 percentagem_idade.head()

```

	Idade	Porcentagem (%)
0	13	0.003140
1	14	0.110692
2	15	1.577171
3	16	6.146962
4	17	16.687078

Desafio 2 - Descobrir de quais estados são os inscritos com 13 anos

```

1 # Desafio 2
2
3 estados = data[data["NU_IDADE"] == 13]['SG_UF_RESIDENCIA'].value_counts().index
4
5 print('Estados:', estados)

```

Estados: ['AP', 'MT', 'BA', 'SP']

Desafio 3 - Distribuição das idades


```

1 # Desafio 3
2
3 fig_idades = go.Figure()
4
5 fig_idades.add_trace(go.Histogram(x = data['NU_IDADE']))
6
7 fig_idades.update_layout(
8     title_text = 'Distribuição das idades',
9     xaxis_title_text = 'Idade',
10    yaxis_title_text = 'Quantidade',
11    template = 'plotly_dark',
12    bargap = .05,
13    width = 750,
14    height = 600
15 )
16

```

```
17 fig_idades.show()
```

Distribuição das idades



▼ Desafio 4 - Distribuição das idades dos treineiros e não treineiros



```
1 # Desafio 4
2
3 treineiros = data[data['IN_TREINEIRO'] == 1]
4 nao_treineiros = data[data['IN_TREINEIRO'] == 0]
5
6 fig_idades = make_subplots(rows = 2,
7                             cols = 1,
8                             subplot_titles = ("Treineiros",
9                                              "Não Treineiros"))
10
11 fig_idades.add_trace(go.Histogram(x = treineiros['NU_IDADE'],
12                                  name = 'Treineiros',
13                                  showlegend = False),
14                       row = 1, col = 1)
15
16 fig_idades.add_trace(go.Histogram(x = nao_treineiros['NU_IDADE'],
```

```

17         name = 'Não Treineiros',
18         showlegend = False),
19         row = 2, col = 1)
20
21 fig_idades.update_xaxes(title_text='Idade')
22
23 fig_idades.update_yaxes(title_text='Quantidade')
24
25 fig_idades.update_layout(
26     title_text = 'Distribuição das idades',
27     template = 'plotly_dark',
28     bargap = .05,
29     width = 750,
30     height = 600
31 )
32
33 fig_idades.show()

```



Distribuição das idades



Desafio 5 - Distribuição das notas de linguagens e códigos nas diferentes línguas (inglês e espanhol).

```
1 # Desafio 05
2
3 prova_espanhol = data[data['TP_LINGUA'] == 1]
4 prova_ingles = data[data['TP_LINGUA'] == 0]
5
6 fig_nota_lc = make_subplots(rows = 1,
7                             cols = 2,
8                             shared_yaxes = True)
9
10 fig_nota_lc.add_trace(go.Box(y = prova_espanhol['NU_NOTA_LC'],
11                             name = 'Espanhol',
12                             marker_color = '#c56183',
13                             showlegend = False),
14                        row = 1, col = 1)
15
16 fig_nota_lc.add_trace(go.Box(y = prova_ingles['NU_NOTA_LC'],
17                             name = 'Ingles',
18                             marker_color = '#fadcaa',
19                             showlegend = False),
20                        row = 1, col = 2)
21
22 fig_nota_lc.update_layout(
23     title_text = 'Distribuição das Notas de Linguagens e Códigos',
24     yaxis_title_text = 'Nota de Linguagens e Códigos',
25     template = 'plotly_dark',
26     bargap = .05,
27     width = 750,
28     height = 600
29 )
30
31 fig_nota_lc.show()
```

Distribuição das Notas de Linguagens e Códigos




▼ Desafio 6 - Gráfico Extra

```

1 colors= ['#c56183', '#fadcaa']
2
3 labels = ['Espanhol', 'Inglês']
4
5 values = [len(prova_espanhol),
6           len(prova_ingles)]
7
8 fig_linguas = go.Figure()
9
10 fig_linguas.add_trace(go.Pie(labels=labels, values=values,
11                               hole=.4, marker_colors=colors))
12
13 fig_linguas.update_layout(
14     title_text='Porcentagem de Linguas Escolhidas - ENEM 2019',
15     template = 'plotly_dark',
16     width = 750,
17     height = 600
18 )
19
20 fig_linguas.show()
```

Porcentagem de Linguas Escolhidas - ENEM 2019



▼ Dia 2 - Desafios



Double-click (or enter) to edit

```
1 provas = [ 'NU_NOTA_CN', 'NU_NOTA_CH',
2           'NU_NOTA_MT', 'NU_NOTA_LC',
3           'NU_NOTA_REDACAO' ]
4
5 presenca_provas = [ 'TP_PRESENCA_CN', 'TP_PRESENCA_CH',
6                   'TP_PRESENCA_MT', 'TP_PRESENCA_LC' ]
7
8
9 data['NU_NOTA_TOTAL'] = data[provas].sum(axis=1)
10
11 data_sem_nota_zero = data[data['NU_NOTA_TOTAL'] != 0]
```

▼ Desafio do Gui Bonzinho - Proporção de participantes menores de idade por estado


```
1 menores_de_idade = data[data['NU_IDADE'] <= 17]
2
3 proporcao_estado = menores_de_idade['SG_UF_RESIDENCIA'].value_counts(normalize =
4
5 fig_menores_de_idade = go.Figure()
6
7 fig_menores_de_idade.add_trace(go.Bar(x = proporcao_estado.index,
8                                       y = proporcao_estado.values))
9
10 fig_menores_de_idade.update_layout(
11     title_text = 'Proporção de participantes menores de idade por estado',
12     xaxis_title_text = 'Estados',
13     yaxis_title_text = 'Proporção de participação (%)',
14     template = 'plotly_dark',
15     width = 750,
```

```

16     height = 600
17 )
18
19 fig_menores_de_idade.show()

```

Proporção de participantes menores de idade por estado



▼ Desafio 3 - Criar uma função para gerar boxplots

```

1 def gerar_boxplot(dados, x, y, ordenar = False):
2
3     '''
4     Retorna um BoxPlot
5
6     Parâmetros:
7     dados : DataFrame
8         Dados a serem utilizados
9     x : String
10        Nome da coluna que contem os valores desejados para o eixo X
11     y : String
12        Nome da coluna que contem os valores desejados para o eixo Y
13     ordenar : Booleano, valor padrão False

```




```

14     Define se os valores exibidos no eixo X serão ordenados ou não
15     '''
16
17     if ordenar:
18         dados_ordenados = dados.sort_values(x, ascending = True)
19         boxplot = px.box(data_frame=dados_ordenados, x = x, y = y)
20     else:
21         boxplot = px.box(data_frame=dados, x = x, y = y)
22
23     boxplot.update_layout(
24         title_text = ('Boxplot - %s x %s' %(x, y)),
25         xaxis_title_text = ('%s' %x),
26         yaxis_title_text = ('%s' %y),
27         template = 'plotly_dark',
28         width = 900,
29         height = 600
30     )
31
32     boxplot.show()

```

```
1 gerar_boxplot(data_sem_nota_zero, 'Q006', 'NU_NOTA_TOTAL', ordenar=True)
```

Boxplot - Q006 x NU_NOTA_TOTAL



Desafio 4 - Verificar se quem tirou a nota total igual a zero foi eliminado ou não estava presente

```
1 situacao_participantes = data[data['NU_NOTA_TOTAL'] == 0][presenca_provas]
2
3 situacao_participantes.value_counts()
```

TP_PRESENCIA_CN	TP_PRESENCIA_CH	TP_PRESENCIA_MT	TP_PRESENCIA_LC	
0	0	0	0	28998
	2	0	2	120
	1	0	1	39
1	0	1	0	3
	1	1	1	2

dtype: int64

```
1 round(situacao_participantes.value_counts(normalize=True) * 100 , 2)
```

TP_PRESENCIA_CN	TP_PRESENCIA_CH	TP_PRESENCIA_MT	TP_PRESENCIA_LC	
0	0	0	0	99.44
	2	0	2	0.41
	1	0	1	0.13
1	0	1	0	0.01
	1	1	1	0.01

dtype: float64

Resultado Desafio 4

Total de participantes com nota total igual a zero na amostra: 29.162

Situações possíveis para nota total igual a zero na amostra:

- Participante faltou em todas as provas realizadas
 - Quantidade: 28.998
 - Porcentagem correspondente: 99.44%
- Participante faltou em algumas provas e foi eliminado em outras
 - Quantidade: 120
 - Porcentagem correspondente: 0.41%
- Participante faltou em alguma das provas e fez outras
 - Quantidade: 42
 - Porcentagem correspondente: 0.14%
- Participante foi em todas as provas objetivas e mesmo assim zerou.
 - Quantidade: 2
 - Porcentagem correspondente: 0.01%

▼ Desafio 5 - Quem foi eliminado tira zero ou NaN

```
1 data[data['TP_PRESENCA_LC'] == 2][provas]
```

	NU_NOTA_CN	NU_NOTA_CH	NU_NOTA_MT	NU_NOTA_LC	NU_NOTA_REDACAO
77	NaN	NaN	NaN	NaN	NaN
396	NaN	NaN	NaN	NaN	NaN
446	NaN	NaN	NaN	NaN	NaN
609	NaN	NaN	NaN	NaN	NaN
728	NaN	NaN	NaN	NaN	NaN
...
124695	NaN	NaN	NaN	NaN	NaN
125216	NaN	NaN	NaN	NaN	NaN
125784	NaN	NaN	NaN	NaN	NaN
126769	NaN	NaN	NaN	NaN	NaN
127122	NaN	NaN	NaN	NaN	NaN

126 rows x 5 columns

Resultado Desafio 5

Aos participantes eliminados não há registro de notas (NaN)

▼ Desafio 6 - Verificar a proporção dos participantes de rendas mais altas e mais baixas como treineiro e não treineiro.

```
1 treineiros = data[data['IN_TREINEIRO'] == 1]
2 nao_treineiros = data[data['IN_TREINEIRO'] == 0]
3
4 proporcao__treineiros_estado = treineiros['Q006'].value_counts(normalize = True)
5 proporcao__nao_treineiros_estado = nao_treineiros['Q006'].value_counts(normalize
6
7 fig_treineiros_renda = go.Figure()
8
9 fig_treineiros_renda.add_trace(go.Bar(x = proporcao__treineiros_estado.index,
10                                     y = proporcao__treineiros_estado.values,
11                                     name = 'Treineiros'))
12
13 fig_treineiros_renda.add_trace(go.Bar(x = proporcao__nao_treineiros_estado.index
14                                     y = proporcao__nao_treineiros_estado.valu
15                                     name = 'Não Treineiros'))
```

25

▼ Desafio 7 - Boxplot olhando para a Q0025 (Acesso a internet)


Situações para Q025:

- Não possui acesso a internet (A)
- Possui acesso a internet (B)

```
1 sem_acesso = data_sem_nota_zero[data_sem_nota_zero['Q025'] == 'A']
2 acesso = data_sem_nota_zero[data_sem_nota_zero['Q025'] == 'B']
3
4 fig_acesso_internet = go.Figure()
5
6
7 fig_acesso_internet.add_trace(go.Box(y = acesso['NU_NOTA_TOTAL'],
8                                     name = 'Acesso à Internet',
9                                     marker_color = '#fadcaa'))
10
11 fig_acesso_internet.add_trace(go.Box(y = sem_acesso['NU_NOTA_TOTAL'],
12                                     name = 'Sem Acesso à Internet',
13                                     marker_color = '#c56183'))
14
15 fig_acesso_internet.update_layout(
16     title_text = 'Boxplot - Acesso a Internet x Nota Total',
17     xaxis_title_text = 'Q025',
18     yaxis_title_text = 'Nota Total',
19     template = 'plotly_dark',
20     width = 900,
21     height = 600
22 )
23
```

```
1 colors= ['#fadcaa', '#c56183']
2
3 labels = ['Acesso à Internet', 'Sem Acesso à Internet']
4
5 values = [len(aceso),
6           len(sem_aceso)]
7
8 fig_linguas = go.Figure()
9
10 fig_linguas.add_trace(go.Pie(labels=labels, values=values,
11                               hole=.4, marker_colors=colors))
12
13 fig_linguas.update_layout(
14     title_text='Porcentagem de participantes - ENEM 2019',
15     template = 'plotly_dark',
16     width = 900,
17     height = 600
18 )
19
20 fig_linguas.show()
```

Porcentagem de participantes - ENEM 2019



▼ Dia 3 - Desafios

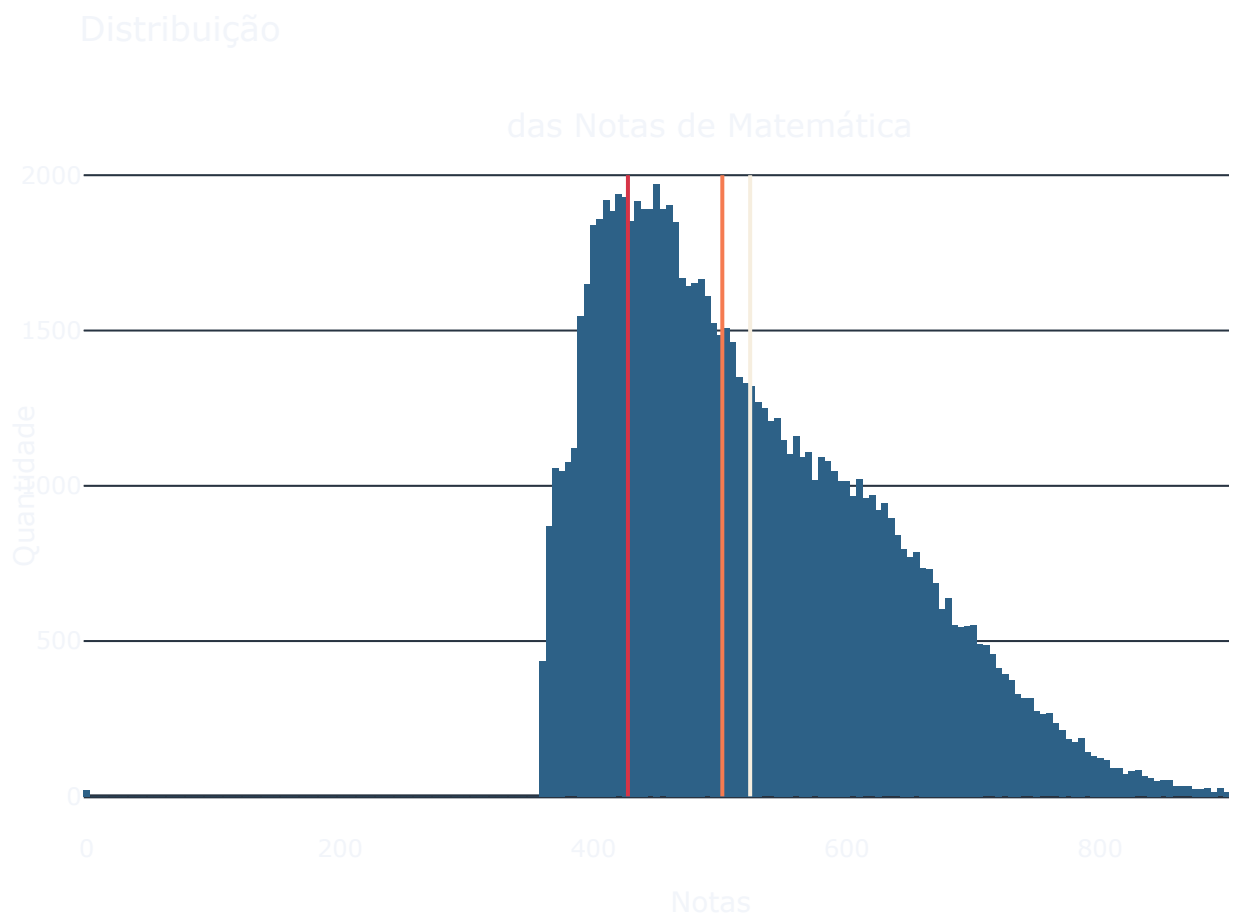
▼ Desafio 1 - Exibir o gráfico de distribuição das notas LC e MT juntamente as suas médias, medianas e moda.

```

1 fig = make_subplots(rows = 1, cols = 2,
2                       subplot_titles = ('das Notas de Matemática',
3                                         'das Notas de Linguagens e Códigos'))
4
5 # Nota matemática
6
7 fig.add_trace(go.Histogram(x = data_sem_nota_zero['NU_NOTA_MT'], name = 'Notas M
8                               marker_color = '#2d6187'), row = 1, col = 1)
9
10
11 fig.add_trace(go.Scatter(x=[data_sem_nota_zero['NU_NOTA_MT'].median(), data_sem_
12                             y=[0,2000],
13                             mode="lines",
14                             legendgroup="Mediana",
15                             showlegend=True,
16                             marker=dict(size=12,
17                                           line=dict(width=0.8),
18                                           color="#f57b51"
19                                           ),
20                             name="Mediana"
21                             ), row = 1, col = 1,)
22
23 fig.add_trace(go.Scatter(x=[data_sem_nota_zero['NU_NOTA_MT'].mean(), data_sem_no
24                             y=[0,2000],
25                             mode="lines",
26                             legendgroup="Média",
27                             showlegend=True,
28                             marker=dict(size=12,
29                                           line=dict(width=0.8),
30                                           color="#f6eedf"
31                                           ),
32                             name="Média"
33                             ), row = 1, col = 1,)
34
35 fig.add_trace(go.Scatter(x=[data_sem_nota_zero['NU_NOTA_MT'].mode()[0], data_sem
36                             y=[0,2000],
37                             mode="lines",
38                             legendgroup="Moda",
39                             showlegend=True,
40                             marker=dict(size=12,
41                                           line=dict(width=0.8),
42                                           color="#d63447"
43                                           ),
44                             name="Moda"

```

```
45         ), row = 1, col = 1,)
46
47 # Nota Lc
48
49 fig.add_trace(go.Histogram(x = data_sem_nota_zero['NU_NOTA_LC'], name = 'Notas L
50         marker_color = '#2d6187'), row = 1, col = 2)
51
52
53 fig.add_trace(go.Scatter(x=[data_sem_nota_zero['NU_NOTA_LC'].median(), data_sem_
54         y=[0,1400],
55         mode="lines",
56         legendgroup="Mediana",
57         showlegend=False,
58         marker=dict(size=12,
59                 line=dict(width=0.8),
60                 color="#f57b51"
61         ),
62         name="Mediana"
63         ), row = 1, col = 2,)
64
65 fig.add_trace(go.Scatter(x=[data_sem_nota_zero['NU_NOTA_LC'].mean(), data_sem_no
66         y=[0,1400],
67         mode="lines",
68         legendgroup="Média",
69         showlegend=False,
70         marker=dict(size=12,
71                 line=dict(width=0.8),
72                 color="#f6eedf",
73         ),
74         name="Média"
75         ), row = 1, col = 2,)
76
77 fig.add_trace(go.Scatter(x=[data_sem_nota_zero['NU_NOTA_LC'].mode()[0], data_sem
78         y=[0,1400],
79         mode="lines",
80         legendgroup="Moda",
81         showlegend=False,
82         marker=dict(size=12,
83                 line=dict(width=0.8),
84                 color="#d63447"
85         ),
86         name="Moda"
87         ), row = 1, col = 2)
88
89 fig.update_xaxes(title_text='Notas')
90
91 fig.update_yaxes(title_text='Quantidade')
92
93 fig.update_layout(
94     title_text = 'Distribuição',
95     template = 'plotly_dark',
96     bargap = .05,
97 )
98
99 fig.show()
```

Resultado Desafio 1

- As notas de Matemática apresentam uma distribuição assimétrica positiva
- As notas de Linguagens e Códigos apresentam uma distribuição assimétrica negativa

Desafio 2 e 3 - Melhorar a visualização da matriz de correlação,
▼ realizar uma análise mais detalhada sobre as correlações e comparar elas entre o Brasil e seu estado.

```
1 correlaca_prova_brasil = data_sem_nota_zero[provas].corr()  
2  
3 correlaca_prova_sp = data_sem_nota_zero[data_sem_nota_zero['SG_UF_RESIDENCIA'] =  
  
1 fig_corr = make_subplots(rows = 1, cols = 2,  
2                           subplot_titles = ('Brasil', 'São Paulo'),  
3                           shared_yaxes = True)  
4  
5
```

```
6 fig_corr.add_trace(go.Heatmap(
7     z=correlaca_prova_brasil,
8     x=['Ciências Naturais', 'Ciências Humanas', 'Matemática', 'Li
9     y=['Ciências Naturais', 'Ciências Humanas', 'Matemática', 'Li
10    colorscale = 'Peach',
11    showscale=False,
12    xgap=1, ygap=1,
13    colorbar_thickness=20,
14    colorbar_ticklen=3,
15    hoverongaps = False),row = 1, col = 1)
16
17
18 fig_corr.add_trace(go.Heatmap(
19     z=correlaca_prova_sp,
20     x=['Ciências Naturais', 'Ciências Humanas', 'Matemática', 'Li
21     y=['Ciências Naturais', 'Ciências Humanas', 'Matemática', 'Li
22     colorscale = 'Peach',
23     xgap = 1, ygap = 1,
24     colorbar_thickness=20,
25     colorbar_ticklen=3,
26     hoverongaps = False),row = 1, col = 2)
27
28 fig_corr.update_layout(
29     title_text = 'Correlação - Notas das Provas',
30     template = 'plotly_dark',
31 )
32
33 fig_corr.show()
```

Correlação - Notas das Provas

Resultado Desafio 2 e 3

Como podemos observar a correlação entre as notas das diversas provas no estado de São Paulo se comporta de forma bem semelhante ao restante do Brasil.



Desafio 4 - Análisar a correlação entre matemática e linguagens.

A existência de uma correlação de 58% entre as notas de matemática e linguagens pode estar associada a casualidade, contudo podemos considerar que esta correlação se faz presente pois os alunos que estudaram para uma das provas tendem a estudar para todas as outras, ou seja, possivelmente um participante pode apresentar um desempenho semelhante nas diferentes provas



▼ Dia 4 - Desafios

Ciências Naturais Ciências Humanas Matemática Linguagens e Códigos Redação

```

1 provas_entrada = ['NU_NOTA_CH', 'NU_NOTA_LC', 'NU_NOTA_CN', 'NU_NOTA_REDACAO']
2 provas_saida = 'NU_NOTA_MT'
3
4 data_sem_nota_zero = data_sem_nota_zero[provas].dropna()

1 X = data_sem_nota_zero[provas_entrada]
2
3 y = data_sem_nota_zero[provas_saida]
4
5 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2)

```

▼ Criando modelos

▼ Modelo - Linear SVR

Baseia-se na elaboração de um equação linear utilizando variáveis independente para prever uma variável dependente.

- Equação linear: $y = a_1x_1 + b$
- No nosso caso:

$$Nota_{MT} = Coef_{Nota_{CH}} * Nota_{CH} + Coef_{Nota_{CN}} * Nota_{CN} + Coef_{Nota_{LC}} * Nota_{LC}$$

```

1 linear_svr = LinearSVR().fit(X_train, y_train)
2

```

```

3 y_pred_linear_svr = linear_svr.predict(X_test)
4
5 mae_linear_svr = mean_absolute_error(y_test, y_pred_linear_svr)
6
7 mse_linear_svr = mean_squared_error(y_test, y_pred_linear_svr)
8
9 rsq_linear_svr = r2_score(y_test, y_pred_linear_svr)

/usr/local/lib/python3.6/dist-packages/sklearn/svm/_base.py:947: ConvergenceWarning:
Liblinear failed to converge, increase the number of iterations.

```

▼ Modelo - Polynomial Regression

É uma extensão ao modelo de regressão linear, pois é capaz de agregar preditores adicionais ao modelo.

Este processo funciona elevando os preditores originais a uma nova potência, possibilitando que o modelo se ajuste a dados não lineares.

Exemplo:

- Equação linear original: $y = a_1x_1 + b$
- Equação polinomial criada: $y = a_1x_1 + a_2x_1^2 + b$
- Caso utilizemos uma potência quadrada, nosso caso ficará assim:


$$Nota_{MT} = Coef_{NotaCH} * NotaCH + Coef_{2NotaCH} * NotaCH^2 + Coef_{NotaCN} * NotaCN + Coef_{NotaLC} * NotaLC + Coef_{2NotaLC} * NotaLC^2 + Coef_{NotaRed} * NotaRED + Coef_{NotaB} * NotaB$$

```

1 polynomial_features = PolynomialFeatures(degree = 2)
2
3 polynomial_features.fit(X_train)
4
5 X_train_poly = polynomial_features.transform(X_train)
6 X_test_poly = polynomial_features.transform(X_test)
7
8 X_poly = polynomial_features.fit_transform(X)
9
10 polynomial_regression = LinearRegression().fit(X_train_poly, y_train)
11
12 y_pred_poly = polynomial_regression.predict(X_test_poly)
13
14 mae_poly = mean_absolute_error(y_test, y_pred_poly)
15
16 mse_poly = mean_squared_error(y_test, y_pred_poly)
17
18 rsq_poly = r2_score(y_test, y_pred_poly)

```

▼ Modelo - Random Forest Regressor



```

1 rfr = RandomForestRegressor().fit(X_train, y_train)
2
3 y_pred_rfr = rfr.predict(X_test)
4
5 mae_rfr = mean_absolute_error(y_test, y_pred_rfr)
6
7 mse_rfr = mean_squared_error(y_test, y_pred_rfr)
8
9 rsq_rfr = r2_score(y_test, y_pred_rfr)

```

▼ Modelo - Dummy Regressor Median

Realiza previsões baseando-se em métricas simples. Neste caso utilizarei a mediana.

```

1 dummy_regressor = DummyRegressor(strategy='median')
2
3 dummy_regressor.fit(X_train, y_train)
4
5 y_pred_dummy = dummy_regressor.predict(X_test)
6
7 mae_dummy_reg = mean_absolute_error(y_test, y_pred_dummy)
8
9 mse_dummy_reg = mean_squared_error(y_test, y_pred_dummy)
10
11 rsq_dummy_reg = r2_score(y_test, y_pred_dummy)

```

▼ Comparando modelos

Métricas utilizadas:

- MAE: É a média da diferença absoluta entre os valores reais e os valores preditos.
- MSE: É a média da diferença quadrada entre os valores reais e os valores preditos.
 - Valor sempre positivo e quanto menor melhor
- R²: Quantifica a diferença entre a linha elaborada pelo equação do modelo de regressão e a média.
 - Valor que varia de 0 a 1, sendo 0 o indicador que o modelo proposto não melhora a predição e 1 o indicador de uma predição perfeita

▼ Através de um DataFrame

```
1 modelos = [('Linear SVR', mae_linear_svr, mse_linear_svr, rsq_rfr),
2             ('Polynomial Regression', mae_poly, mse_poly, rsq_poly),
3             ('Random Forest Regressor', mae_rfr, mse_rfr, rsq_rfr),
4             ('Dummy Regressor', mae_dummy_reg, mse_dummy_reg, rsq_dummy_reg)]
5
6 df_comparando_modelos = pd.DataFrame(modelos, columns = ['Modelo', 'MAE', 'MSE',
7
8 df_comparando_modelos.head()
```

	Modelo	MAE	MSE	R ²
0	Linear SVR	74.069213	8754.081890	0.515917
1	Polynomial Regression	58.782090	5397.478485	0.542046
2	Random Forest Regressor	60.318493	5705.436794	0.515917
3	Dummy Regressor	88.105046	12274.403152	-0.041434

▼ Gráficamente

```
1 fig_prediction = make_subplots(rows = 2, cols = 2,
2
3                                 subplot_titles = (("Linear SVR (R² = %.4f)" %rsq_
4                                                    ("Polynomial (R² = %.4f)" %rsq_
5                                                    ("RFR (R² = %.4f)" %rsq_rfr),
6                                                    ("Dummy Median (R² = %.4f)" %rs
7
8 # Linear Regression
9
10 fig_prediction.add_trace(go.Scatter(x = y_test,
11                                     y = y_test,
12                                     marker_color = '#3da4ff',
13                                     name = 'Predição Perfeita'),
14                                     row = 1, col = 1)
```

```
15
16 fig_prediction.add_trace(go.Scatter(x = y_test,
17                                     y = y_pred_linear_svr,
18                                     marker_color = '#ff3e3b',
19                                     mode = 'markers',
20                                     name = 'Predições Realizadas'),
21                                row = 1, col = 1)
22
23 # Polynomial Regression
24
25 fig_prediction.add_trace(go.Scatter(x = y_test,
26                                     y = y_test,
27                                     marker_color = '#3da4ff',
28                                     name = 'Predição Perfeita',
29                                     showlegend = False),
30                                row = 1, col = 2)
31
32
33 fig_prediction.add_trace(go.Scatter(x = y_test,
34                                     y = y_pred_poly,
35                                     marker_color = '#ff3e3b',
36                                     mode = 'markers',
37                                     name = 'Predição Realizadas',
38                                     showlegend = False),
39                                row = 1, col = 2)
40
41 # RFR
42
43 fig_prediction.add_trace(go.Scatter(x = y_test,
44                                     y = y_test,
45                                     marker_color = '#3da4ff',
46                                     name = 'Predição Perfeita',
47                                     showlegend = False),
48                                row = 2, col = 1)
49
50
51 fig_prediction.add_trace(go.Scatter(x = y_test,
52                                     y = y_pred_rfr,
53                                     marker_color = '#ff3e3b',
54                                     mode = 'markers',
55                                     name = 'Predições Realizadas',
56                                     showlegend = False),
57                                row = 2, col = 1)
58
59 # Dummy Regressor
60
61 fig_prediction.add_trace(go.Scatter(x = y_test,
62                                     y = y_test,
63                                     marker_color = '#3da4ff',
64                                     name = 'Predição Perfeita',
65                                     showlegend = False),
66                                row = 2, col = 2)
67
68
69 fig_prediction.add_trace(go.Scatter(x = y_test,
```

```

70         y = y_pred_dummy,
71         marker_color = '#ff3e3b',
72         mode = 'markers',
73         name = 'Predições Realizadas',
74         showlegend = False),
75         row = 2, col = 2)
76
77 fig_prediction.update_xaxes(title_text='Nota Real')
78
79 fig_prediction.update_yaxes(title_text='Nota Prevista')
80
81 fig_prediction.update_layout(
82
83     template = 'plotly_dark',
84     width = 1150,
85     height = 600
86 )
87
88
89 fig_prediction.show()

```

